

PARTE 1 IC - O que é IA e LLM

O que é Inteligência Artificial

Para o início dos estudos, torna-se necessário compreender o conceito de Inteligência Artificial (IA). Trata-se de um campo da ciência da computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que tradicionalmente exigem inteligência humana, incluindo raciocínio, aprendizado, percepção e tomada de decisão. Em definição mais precisa, a IA é composta por softwares que transferem capacidades humanas para computadores, realizando atividades cognitivas fundamentadas em dados, instruções e objetivos definidos (IBM, 2024; Google Cloud, 2025).

Russell e Norvig, autores da obra “Artificial Intelligence: A Modern Approach”, agrupam as definições de IA em quatro categorias principais: sistemas que pensam como humanos, sistemas que agem como humanos, sistemas que pensam racionalmente e sistemas que agem racionalmente. Essa taxonomia evidencia que não há plena convergência quanto ao conceito técnico de IA e sua abrangência (Russell & Norvig, 2020; Frontiers in Artificial Intelligence, 2020).

A IA moderna consiste em um conjunto de tecnologias que permitem aos computadores executar funções avançadas, tais como compreender e traduzir idiomas, analisar dados e fazer recomendações. O conceito remete a discussões filosóficas antigas sobre a mente, mas foi formalizado após a Segunda Guerra Mundial, com o avanço da computação. Em 1950, Alan Turing propôs o Teste de Turing como critério para avaliar inteligência em máquinas, enquanto a Conferência de Dartmouth, em 1956, consolidou o campo da IA (NASA, 2024; ISO, 2024).

O campo envolve múltiplas disciplinas, como ciência da computação, estatística, engenharia, linguística, neurociência e filosofia. Operacionalmente, a IA utiliza métodos de aprendizado de máquina (*machine learning*) e aprendizado profundo (*deep learning*) para análise de dados, previsões, categorização de objetos e processamento de linguagem natural (Goodfellow et al., 2016; Barroso, 2024).

Aprendizado Profundo (Deep Learning)

O aprendizado profundo (*deep learning*) constitui um subcampo especializado do aprendizado de máquina baseado em redes neurais artificiais com múltiplas camadas de processamento. Diferente do *machine learning* tradicional, que requer engenharia manual de características, o *deep learning* automaticamente aprende representações hierárquicas dos dados, onde cada camada extrai características progressivamente mais abstratas e complexas. Essa capacidade de aprendizado automático de representações torna o *deep learning* particularmente eficaz para

processar grandes volumes de dados não-estruturados, como imagens, áudio e texto (Goodfellow et al., 2016; LeCun et al., 2015).

A arquitetura fundamental do *deep learning* inspira-se no funcionamento do cérebro humano, organizando-se em camadas de neurônios artificiais interconectados. Uma rede neural profunda típica compõe-se de uma camada de entrada (que recebe dados brutos), múltiplas camadas ocultas (*hidden layers*, onde ocorrem as transformações e o aprendizado), e uma camada de saída (que produz a predição final). O termo "profundo" refere-se justamente à presença de múltiplas camadas ocultas (geralmente duas ou mais) que permitem ao modelo aprender padrões complexos através de níveis hierárquicos de abstração. Em aplicações de visão computacional, por exemplo, as primeiras camadas detectam características simples como bordas e texturas, camadas intermediárias reconhecem formas e padrões geométricos, enquanto camadas mais profundas identificam objetos completos e conceitos semânticos de alto nível (Wikipedia Neural Networks, 2024; DataCamp Introduction to Deep Neural Networks, 2023).

O treinamento de redes profundas ocorre através do algoritmo de *backpropagation* (retropropagação), que ajusta iterativamente os pesos das conexões entre neurônios para minimizar o erro de predição. O processo divide-se em duas fases: o *forward pass*, onde dados fluem da entrada até a saída gerando uma predição, e o *backward pass*, onde o erro é propagado de volta através da rede usando a regra da cadeia do cálculo, permitindo calcular quanto cada peso contribuiu para o erro total. Esses gradientes guiam a atualização dos pesos através de algoritmos de otimização como *stochastic gradient descent* (SGD), que realiza pequenos ajustes incrementais ao longo de milhares ou milhões de iterações até que a rede atinja desempenho satisfatório (Rumelhart et al., 1986; Goodfellow et al., 2016).

Inovações técnicas foram cruciais para viabilizar redes profundas modernas. A função de ativação ReLU (*Rectified Linear Unit*), introduzida por Nair e Hinton (2010), tornou-se padrão por mitigar o problema do gradiente-desaparecedor (fenômeno onde gradientes diminuem exponencialmente em redes muito profundas, impedindo o aprendizado eficaz). Técnicas de regularização como *dropout*, que desativa aleatoriamente neurônios durante treinamento, e batch normalization, que normaliza ativações entre camadas, aumentam a robustez e estabilidade do treinamento. Arquiteturas especializadas emergiram para domínios específicos: Redes Neurais Convolucionais (CNNs) para visão computacional, que aplicam filtros convolucionais para extrair características espaciais; e Redes Neurais Recorrentes (RNNs) e suas variantes como LSTM para dados sequenciais, capazes de capturar dependências temporais em texto e séries temporais (Krizhevsky et al., 2012; Hochreiter & Schmidhuber, 1997; Ioffe & Szegedy, 2015).

Como Funcionam os *Large Language Models*

Os *Large Language Models* (LLMs) representam modelos avançados de aprendizado profundo treinados com grandes volumes de dados para identificar padrões e gerar conteúdo linguístico. Um LLM é construído a partir de algoritmos capazes de realizar tarefas complexas de processamento de linguagem natural (Naveed et al., 2023; Raiaan et al., 2024).

A arquitetura central dos LLMs é baseada em *transformers*, modelos projetados para detectar dependências entre diferentes elementos de uma sequência de dados. O artigo “Attention Is All You Need” introduziu essa arquitetura inovadora, alicerçada em mecanismos de atenção, dispensando convoluções e recorrências (Vaswani et al., 2017; Islam et al., 2024).

O funcionamento de um LLM pode ser dividido em três componentes principais: camada de incorporação (*embedding*), mecanismo de atenção e camada de avanço direto (*feedforward*). O *embedding* transforma termos em representações vetoriais; a atenção destaca partes relevantes do texto; e a *feedforward* executa transformações não lineares nos dados codificados. Assim, percebe-se que uma LLM não sabe o que fazer, mas sim, o que falar. Ou seja, o modelo limita-se à geração de sequências linguísticas baseadas em padrões estatísticos aprendidos durante o treinamento, sem consciência, intenção ou entendimento real do contexto. (DataCamp, 2024; Microsoft Learn, 2025).

O treinamento ocorre em duas etapas: pré-treinamento, utilizando grandes conjuntos de dados públicos, e ajuste fino (*fine-tuning*), focado em tarefas específicas com conjuntos supervisionados menores (Douglas, 2023; Ferraris, 2025).

Modelos como o BERT (*Bidirectional Encoder Representations for Transformers*) e o GPT (*Generative Pre-trained Transformer*) representam abordagens distintas. O BERT é bidirecional e foca na compreensão de contexto; o GPT emprega arquitetura de decodificador para geração textual. O GPT-4, lançado em 2023, apresenta desempenho de compreensão e produção em nível humano (Devlin et al., 2019; OpenAI, 2023; Achiam et al., 2023).

Diferença e Conexão entre IA e LLM

A relação entre IA e LLM é hierárquica: LLMs são módulos dentro do escopo maior da IA. A IA engloba técnicas variadas de tomada de decisão; LLMs formam uma subcategoria voltada ao processamento linguisticamente orientado (SurgeGraph, 2025; T6 HUB, 2025).

Enquanto a IA pode tratar dados de diferentes tipos (imagens, números, texto), LLMs são especializados em linguagem natural. Estes modelos fazem parte da chamada IA generativa, capaz de criar conteúdo original a partir de comandos (Brains.dev, 2024; Microsoft Learn, 2025).

Todos os LLMs são exemplos de IA generativa, porém IA generativa não se limita apenas a modelos de linguagem, inclui também sistemas que geram imagens, áudio e vídeo (Nature, 2025; Pessanha et al., 2024).

Os LLMs utilizam aprendizado profundo (*deep learning*) para modelar conceitos complexos por meio de múltiplas camadas hierárquicas (Goodfellow et al., 2016; Raiaan et al., 2024).

Estes modelos alimentam aplicações voltadas à análise, classificação de texto, detecção de sentimento e geração de respostas coerentes (Jornal da USP, 2024; Repositório Institucional UFC, 2025).

Considerações Finais

A IA e os LLMs representam campos em contínua evolução, com impactos em setores diversos. Os LLMs baseados em transformers revolucionaram o processamento de linguagem natural, atingindo capacidades próximas ao entendimento humano (Vaswani et al., 2017; Naveed et al., 2023).

A evolução para modelos como GPT-4, GPT-5 e arquiteturas bidirecionais demonstra avanço exponencial em potência e sofisticação. Questões de escalabilidade, viés, impacto ambiental e ética são cada vez mais centrais e demandam abordagens responsáveis (Ferraris, 2025; Barroso, 2024; Nature, 2025).

Referências Bibliográficas

Achiam, J., et al. (2023). GPT-4 Technical Report. arXiv preprint arXiv:2303.08774. Disponível em: <https://arxiv.org/abs/2303.08774>

Barroso, L. R. (2024). Inteligência artificial: promessas, riscos e regulação. Algo de novo no front? Revista de Direito Processual, SciELO. Disponível em: <https://www.scielo.br/j/rdp/a/n89PjvWXTdthJJKwb6TtYXy/>

Brains.dev (2024). Introdução aos LLMs e à IA Generativa. Disponível em: <https://brains.dev/2023/introducao-aos-llms-e-a-ia-generativa/>

Coursera (2025). What Is Artificial Intelligence? Definition, Uses, and Types. Disponível em: <https://www.coursera.org/articles/what-is-artificial-intelligence>

DataCamp (2023). Introduction to Deep Neural Networks. Disponível em: <https://www.datacamp.com>

DataCamp (2024). How Transformers Work: A Detailed Exploration. Disponível em: <https://www.datacamp.com/tutorial/how-transformers-work>

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv preprint arXiv:1810.04805. Disponível em: <https://arxiv.org/abs/1810.04805>

Douglas, M. R. (2023). Large Language Models. arXiv preprint arXiv:2307.05782. Disponível em: <https://arxiv.org/abs/2307.05782>

Elastic (2023). O que são grandes modelos de linguagem (LLMs)? Disponível em: <https://www.elastic.co/pt/what-is/large-language-models>

Ferraris, A. F. (2025). Understanding the mechanics behind LLMs. Cambridge Forum on AI Law and Governance. Disponível em: <https://www.cambridge.org/core/journals/cambridge-forum-on-ai-law-and-governance/article/architecture-of-language-understanding-the-mechanics-behind-llms/E3DDEFB9C04883733380E04331D6F782>

Frontiers in Artificial Intelligence (2020). Artificial Intelligence: A Clarification of Misconceptions, Myths and Desired Status. Disponível em: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2020.524339/full>

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. Disponível em: <https://www.deeplearningbook.org>

Google Cloud (2025). O que é inteligência artificial (IA)? Disponível em: <https://cloud.google.com/learn/what-is-artificial-intelligence?hl=pt-BR>

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735-1780.

IBM (2024). O que é inteligência artificial (IA)? Disponível em: <https://www.ibm.com/br-pt/think/topics/artificial-intelligence>

International Organization for Standardization (ISO) (2024). What is artificial intelligence (AI)? Disponível em: <https://www.iso.org/artificial-intelligence/what-is-ai>

Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of the 32nd International Conference on Machine Learning (ICML).

Islam, S., et al. (2024). A comprehensive survey on applications of transformers for deep learning tasks. ScienceDirect. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0957417423031688>

Jornal da USP (2024). Inteligência artificial e os impactos dos grandes modelos de linguagem na educação e na cultura informativa. Disponível em: <https://jornal.usp.br/artigos/inteligencia-artificial-e-os-impactos-dos-grandes-modelos-de-linguagem-na-educacao-e-na-cultura-informativa/>

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet Classification with Deep Convolutional Neural Networks. Advances in Neural Information Processing Systems (NIPS), 25.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444. DOI: 10.1038/nature14539

Microsoft Learn (2025). Como funcionam a IA Generativa e os LLMs. Disponível em: <https://learn.microsoft.com/pt-br/dotnet/ai/conceptual/how-genai-and-llms-work>

Nair, V., & Hinton, G. E. (2010). Rectified Linear Units Improve Restricted Boltzmann Machines. Proceedings of the 27th International Conference on Machine Learning (ICML).

NASA (2024). What is Artificial Intelligence? Disponível em: <https://www.nasa.gov/what-is-artificial-intelligence/>

Nature (2025). What large language models know and what people think they know. Disponível em: <https://www.nature.com/articles/s42256-024-00976-7>

Naveed, H., Khan, A. U., Qiu, S., Saqib, M., Anwar, S., Usman, M., Akhtar, N., Barnes, N., & Mian, A. (2023). A Comprehensive Overview of Large Language

Models. arXiv preprint arXiv:2307.06435. Disponível em: <https://arxiv.org/abs/2307.06435>

OpenAI (2023). GPT-4. Disponível em: <https://openai.com/index/gpt-4-research/>

Pessanha, G. R. G., et al. (2024). Large Language Models (LLMs): A systematic study. SciELO - Revista de Administração Mackenzie. Disponível em: <https://www.scielo.br/j/ram/a/GCJHtgxWBNVv7kB73pKbm5m/>

Raiaan, M. A. K., et al. (2024). A Review on Large Language Models: Architectures. IEEE Xplore. Disponível em: <https://ieeexplore.ieee.org/document/10433480/>

Repositório Institucional UFC (2025). Impacto dos Large Language Models no aprendizado de desenvolvimento de software. Disponível em: https://repositorio.ufc.br/bitstream/riufc/80587/1/2025_tcc_akeportela.pdf

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323(6088), 533-536.

Russell, S. J., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4th ed.). Pearson. ISBN: 978-0134610993

SciELO Brasil (2025). Uso da inteligência artificial na elaboração de artigos científicos. Acta Paulista de Enfermagem. Disponível em: <https://www.scielo.br/j/ape/a/6vTxbwTCLVswNx3LBPTStKG/?lang=pt>

SurgeGraph (2025). Stop Guessing: What Is the Difference Between LLMs and AI? Disponível em: <https://surgegraph.io/ai/what-is-the-difference-between-llms-and-ai>

T6 HUB (2025). IA e LLM | Como funcionam e suas aplicações. Disponível em: <https://blog.tech6group.com/ia-e-llm-como-funcionam-e-suas-aplicacoes/>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. Advances in Neural Information Processing Systems (NIPS 2017). arXiv:1706.03762. Disponível em: <https://arxiv.org/abs/1706.03762>

Wikipedia (2024). Neural network (machine learning). Disponível em: [https://en.wikipedia.org/wiki/Neural_network_\(machine_learning\)](https://en.wikipedia.org/wiki/Neural_network_(machine_learning))